PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Modelo de documentação da entrega

Projeto: Análise Global de Culinárias, Complexidade Culinária e Perfis Nutricionais

Curso e turma: Sistemas de Informação • Turma A • 6º Período

Professor ou professora: Marina de Lara

Equipe: Giovani Nota Simões, Sarah Maneira, Enzo Ricardo, Luan Vieira

Repositório: https://github.com/giovanisims/Dishly-Data

Entrega: Curitiba • 21/10/2026

Este documento acompanha a implementação no repositório. Registre o caminho dos arquivos, notebooks ou células que comprovam cada etapa. O resultado do RA1 será a base para os próximos RAs.

RA1 / 01

Problema e perguntas analíticas

Defina o contexto do projeto e as perguntas que orientarão a seleção e a preparação dos dados.

Contexto e problema

Plataformas de receitas como o Food.com acumulam centenas de milhares de receitas enviadas por usuários ao redor do mundo. Contudo, a ausência de padronização no cadastro gera distorções como tempos de preparo irreais, informações nutricionais armazenadas como listas em texto e culinária ou tipo de dieta registrados apenas em tags livres, sem um campo próprio.

O problema investigado consiste em compreender como diferentes culinárias globais e restrições alimentares se diferenciam em tempo de preparo, complexidade e perfil nutricional. Essas informações são úteis para plataformas nutricionais, sistemas de recomendação de receitas e consumidores que buscam conciliar preferências culturais com metas nutricionais e pouco tempo para cozinhar.

Objetivo e recorte

Objetivo: obter os dados do Food.com de forma reproduzível, diagnosticar seus problemas de qualidade e gerar uma base limpa e documentada.

Unidade de análise: Receitas publicadas no Food.com entre 1999 e 2018. As perguntas por culinária (P1 a P5) usam o subconjunto de receitas com culinária regional ou nacional identificável nas tags. As perguntas P6 a P8 usam todas as receitas.

Limites do projeto: O escopo restringe-se à ingestão automatizada, diagnóstico de qualidade, desempacotamento de variáveis multivaloradas, padronização de tipos e tratamento de anomalias cadastrais, sem realização de agregações estatísticas ou visualizações analíticas.

Perguntas analíticas

Exemplo de formulação: Como [medida] varia entre [grupos] no período [recorte]? Neste RA, formule as perguntas; as respostas serão desenvolvidas nas próximas etapas.

ID	Pergunta a investigar	Dados necessários
P1	Como o tempo de preparo varia entre as principais culinárias globais nas receitas publicadas entre 1999 e 2018?	cuisine_primary, minutes, submitted.

ID	Pergunta a investigar	Dados necessários
P2	Como a complexidade das receitas varia entre as principais culinárias globais entre 1999 e 2018?	cuisine_primary, n_steps, n_ingredients, submitted
P3	Como as calorias por porção variam entre as principais culinárias globais entre 1999 e 2018?	cuisine_primary, calories (extraído de nutrition), submitted
P4	Como os teores de gordura, gordura saturada, açúcar, sódio, proteína e carboidratos por porção variam entre as principais culinárias globais entre 1999 e 2018?	cuisine_primary, total_fat_pdv, saturated_fat_pdv, sugar_pdv, sodium_pdv, protein_pdv, carbohydrates_pdv (extraídos de nutrition), submitted
P5	Como a proporção de receitas com restrição alimentar varia entre as principais culinárias globais entre 1999 e 2018?	cuisine_primary, dietary_tags (extraído de tags), submitted
P6	Como as calorias e os teores de gordura, açúcar e sódio por porção variam entre receitas com e sem restrição alimentar entre 1999 e 2018?	dietary_tags, calories, total_fat_pdv, sugar_pdv, sodium_pdv, submitted
P7	Como o tempo de preparo mediano de preparo das receitas publicadas variou ano a ano entre 1999 e 2018?	submitted (convertido para data, ano extraído), minutes

Viabilidade inicial

O conjunto de dados RAW_recipes.csv possui 231.637 receitas e contém todos os atributos brutos necessários para responder às perguntas. As principais lacunas são:

1. Os 7 indicadores nutricionais estão em uma única coluna (nutrition), armazenados como texto em forma de lista, e precisam ser separados em colunas numéricas.

2. A culinária de origem e restrições alimentares não possuem colunas dedicadas, estando embutidas na lista de tags
3. A coluna submitted está armazenada como texto e precisa ser convertida para data, permitindo o recorte do período e a análise por ano.
4. A coluna minutes apresenta valores impossíveis, como receitas com 0 minuto e valores extremamente altos, que precisam ser tratados.

RA1 / 02

Fontes de dados e ingestão

Documente a origem dos dados e como eles são carregados no ambiente do projeto. Duplique a ficha para cada fonte.

Ficha da fonte

Identificação: F1 • Food.com Recipes and Interactions (RAW_recipes.csv)

Origem e acesso: Majumder et al. (UC San Diego) / Repositório Kaggle (shuyangli94/food-com-recipes-and-user-interactions) • Disponível em: https://www.kaggle.com/datasets/shuyangli94/food-com-recipes-and-user-interactions?select=RAW_recipes.csv • Acesso em: 21 out. de 2026.

Formato e volume: Arquivo CSV (UTF-8) • 231.637 registros • 12 atributos originais (~290 MB descompactado).

Cobertura: Submissões realizadas entre 1999 e 2018 • Abrangência global.

Condições de uso: licença informada no Kaggle: “Data files © Original Authors” (os direitos pertencem aos autores originais). A base é usada apenas para fins acadêmicos, com citação do artigo de origem.

Relação com o problema

A fonte contém o tempo de preparo, o número de etapas e de ingredientes, a informação nutricional e a data de publicação de cada receita, além das tags livres de onde serão extraídas a culinária e as restrições alimentares.

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Download automatizado e reprodutível via biblioteca kagglehub, evitando armazenamento manual de arquivos grandes no Git.	notebooks/RA1_Ingestion_Quality.ipynb (Célula 2)
2	Leitura do arquivo com pd.read_csv.	notebooks/RA1_Ingestion_Quality.ipynb (Célula 2)
3	Verificação das dimensões iniciais, listagem de tipos e inspeção amostral.	notebooks/RA1_Ingestion_Quality.ipynb (Célula 4)

Resultado da ingestão

Foram carregados exatamente 231.637 registros e 12 colunas no ambiente de execução. O arquivo bruto é armazenado automaticamente em cache local pelo kagglehub e copiado/referenciado para leitura direta pelo Pandas sem necessidade de intervenção manual.

RA1 / 03

Compreensão e qualidade

Descreva o que cada registro representa e apresente evidências das verificações de qualidade relevantes para os dados.

Unidade de observação: Uma linha representa uma receita culinária única cadastrada por um colaborador na plataforma Food.com.

Identificação dos registros: Chave primária natural representada pelo atributo id. Embora id seja único em 100% da base, o par de name e contributor_id revelam submissões duplicadas de receitas com o mesmo título.

Dicionário inicial dos dados

Atributo	Significado	Tipo e formato	Unidade ou domínio
name	Nome da receita	object (string)	Texto livre
id	Identificador único da receita na plataforma	int64	Inteiro positivo
minutes	Tempo total estimado de preparo	int64	Minutos >= 0
contributor_id	Identificador único do usuário autor	int64	Inteiro positivo
submitted	Data de publicação da receita	object (string)	Datas entre 1999 e 2018
tags	Lista de palavras-chave	object (string)	Lista de strings
nutrition	Vetor com 7 indicadores nutricionais	object (string)	[calories, total_fat_pdv, sugar_pdv, sodium_pdv, protein_pdv, saturated_fat_pdv, carbohydrates_pdv]
n_steps	Quantidade de passos de preparo	int64	Contagem inteira >= 0
steps	Descrição textual sequencial do modo de preparo	object (string)	Lista de strings
description	Texto introdutório ou comentários do autor	object (string)	Texto livre
ingredients	Lista dos ingredientes utilizados na receita	object (string)	Lista de strings
n_ingredients	Quantidade total de ingredientes da receita	int64	Contagem inteira >= 1

Diagnóstico de qualidade

Considere ausências, duplicidades, tipos, formatos, valores inválidos, categorias e possíveis outliers. Registre também verificações sem problemas; use "não se aplica" com justificativa quando necessário.

ID	Verificação e regra	Resultado observado	Evidência
Q1	name • ausência / nome da receita deve estar preenchido	1 nulo em 231.637 registros (≈0,0004%)	Célula 5
Q2	description • ausência / campo opcional de texto livre	4.979 nulos (2,15%). Esperado, já que a descrição é opcional	Célula 5
Q3	Demais 10 colunas • ausência / devem estar completas	0 nulos. Sem problema	Células 4 e 5
Q4	submitted • tipo / deveria ser data (datetime)	Armazenado como object (texto). Precisa de conversão	Célula 4
Q5	tags, nutrition, steps, ingredients • formato / deveriam ser listas	Armazenados como texto que representa lista. Precisam de conversão para análise	Células 3 e 4
Q6	id • unicidade / chave não pode repetir	0 repetidos. 100% único. Sem problema	Célula 6
Q7	name + contributor_id • duplicidade lógica / mesma receita não deve ser cadastrada duas vezes pelo mesmo autor	5 registros duplicados (≈0,002%)	Célula 7
Q8	minutes • valores inválidos / tempo de preparo deve ser > 0	1.094 receitas com 0 minutos (≈0,47%)	Célula 8
Q9	minutes • outliers / tempo de preparo deve ser plausível (até 1 dia)	2.000 receitas acima de 1 dia (≈0,86%). Maior valor: 2.147.483.647 min (≈4 mil anos), erro claro. A média (9.398 min) fica muito acima da mediana (40 min) por causa desses valores. Entre os maiores existem também receitas de piada e receitas legítimas de fermentação, como licores e hidromel.	Células 8 e 9
Q10	n_steps • domínio / receita deve ter ao menos 1 passo	1 receita com 0 passos	Célula 10
Q11	n_ingredients • domínio / contagem >= 1	0 abaixo de 1. Máx. 43. Sem problema	Célula 10
Q12	submitted • formato e domínio / data válida entre 1999 e 2018	0 datas inválidas. Intervalo de 06/08/1999 a 04/12/2018. Sem problema	Célula 11
Q13	n_steps e n_ingredients • consistência / devem bater com o tamanho das listas	0 divergências nas duas colunas. Sem problema	Célula 13

ID	Verificação e regra	Resultado observado	Evidência
Q14	nutrition • formato e valores / 7 indicadores, sem negativos e com calorias plausíveis	Todas com 7 valores e 0 negativos. Calorias com máximo de 434.360 kcal contra mediana de 313 kcal: valores exagerados	Célula 14
Q15	tags • categorias / toda receita deve ter ao menos 1 tag	0 receitas sem tag. Sem problema	Célula 15

Impacto dos problemas identificados

O problema mais grave é o atributo *minutes*. 1.094 receitas tem o tempo de preparo igual a zero e 2.000 receitas com mais de um dia de preparo, incluindo um valor de 2.147.483.647 minutos, claramente um erro de cadastro. Esses valores distorcem qualquer cálculo de tempo: a média ficou em 9.398 minutos, enquanto a mediana é de apenas 40. Por isso, qualquer análise de tempo de preparo feita sem tratamento dessa coluna vai estar errada, o que torna esse problema a primeira prioridade. Porém nem todo valor alto é erro, já que algumas receitas de fermentaçãolevam meses de fato. Os casos precisam ser avaliados antes de serem removidos.

O mesmo tipo de problema aparece nas calorias, o valor máximo é de 434.360 kcal para uma única receita, contra uma mediana de 313 kcal. Isso compromete análises nutricionais e deve ser tratado com prioridade.

Também é prioritário converter as colunas tags, nutrition, steps e ingredients, que estão armazenadas como texto. Sem essa conversão não é possível contar ingredientes, analisar categorias ou calcular indicadores nutricionais. A correção é simples, mas sem ela, boa parte da base não pode ser usada.

Os demais problemas têm impacto baixo por envolverem poucos registros: 5 receitas duplicadas, 1 receita sem nome e 1 receita sem passos de preparo. Eles devem ser corrigidos para garantir a consistência da base, mas não alteram os resultados de forma significativa. A ausência de description em 4.979 receitas é esperada, por se tratar de um campo opcional, e só seria relevante numa análise de texto. Já a conversão de submitted para data é necessária apenas para análises ao longo do tempo.

Por fim, várias verificações não apontaram problemas: o id é único, as datas estão dentro do período esperado, as contagens de passos e ingredientes batem com as listas e todas as receitas têm pelo menos uma tag. Isso indica que, com exceção dos pontos citados, a base é consistente e confiável para análise.

RA1 / 04

Limpeza e preparação

Relacione cada intervenção ao diagnóstico. Justifique tanto os tratamentos realizados quanto as decisões de manter os dados.

Registro das decisões

Duplique este bloco para cada decisão relevante. Não é necessário aplicar todas as técnicas. Um valor extremo, por si só, não justifica exclusão.

1. Decisão e diagnóstico

D1 • relacionado a Q7

Problema e abrangência

Colunas '*name*' e *'contributor_id'*. 5 receitas cadastradas mais de uma vez pelo mesmo autor, com id diferente.

Tratamento e justificativa

Remoção das duplicatas, mantendo a primeira ocorrência de cada receita. Manter as cópias faria a mesma receita ser contada duas vezes em contagens e rankings. A perda é mínima (5 registros, ≈0,002% da base).

Implementação

Célula D1

```
df = df.drop_duplicates(subset=["name", "contributor_id"], keep="first")
```

Validação após o tratamento

5 linhas removidas. Uma nova verificação de duplicidade retornou 0 duplicadas restantes.

```
# D1 remover receitas duplicadas (mesmo nome e mesmo autor)
antes = len(df)
df = df.drop_duplicates(subset=["name", "contributor_id"], keep="first")
print("Linhas removidas:", antes - len(df))
print("Duplicadas restantes:", df.duplicated(subset=["name", "contributor_id"]).sum())
```

```
Linhas removidas: 5
Duplicadas restantes: 0
```

2. Decisão e diagnóstico

D2 • relacionado a Q1 e Q10

Problema e abrangência

1 receita sem '*name*' e 1 receita com '*n_steps' = 0,* ou seja, sem modo de preparo. 2 registros no total.

Tratamento e justificativa

Remoção dos dois registros. Uma receita sem nome não pode ser identificada nem verificada quanto à duplicidade, e uma receita sem passos não cumpre a função de receita. Como são apenas 2 registros, a remoção não afeta as análises.

Implementação

Célula D2

```
df = df[df["name"].notna() & (df["n_steps"] > 0)]
```

Validação após o tratamento

2 linhas removidas. 0 receitas sem nome e 0 receitas sem passos restantes.

```
# D2 remover receita sem nome e receita sem passos
antes = len(df)
df = df[df["name"].notna() & (df["n_steps"] > 0)]
print("Linhas removidas:", antes - len(df))
print("Sem nome restantes:", df["name"].isna().sum())
print("Sem passos restantes:", (df["n_steps"] == 0).sum())
```

```
Linhas removidas: 2
Sem nome restantes: 0
Sem passos restantes: 0
```

3. Decisão e diagnóstico

D3 • relacionado a Q2

Problema e abrangência

Coluna '*description*', com 4.979 valores ausentes (2,15%).

Tratamento e justificativa

Decisão de manter os registros sem alteração. A descrição é um campo opcional de texto livre, e sua ausência não compromete as demais informações da receita. Remover esses registros descartaria 4.979 receitas válidas sem necessidade.

Implementação

Célula D3

Não se aplica (decisão de manter).

Validação após o tratamento

Os 4.979 registros sem descrição continuam na base, confirmando que nenhum foi removido.

```
# D3 description mantida, só conferindo
print("Receitas sem description (mantidas):", df["description"].isna().sum())
```

```
Receitas sem description (mantidas): 4979
```

4. Decisão e diagnóstico

D4 • relacionado a Q8 e Q9

Problema e abrangência

Coluna '*minutes*'. 1.094 receitas com tempo igual a 0 e 1 receita com 2.147.483.647 minutos (≈4 mil anos), valor que corresponde ao limite de um inteiro de 32 bits e indica erro de cadastro.

Tratamento e justificativa

Esses 1.095 valores foram substituídos por ausente, sem remover as receitas, já que os demais atributos delas continuam válidos. Os outros tempos acima de 1 dia foram mantidos, porque parte deles é real, como receitas de fermentação, licores e extrato de baunilha, e só um valor extremo não justifica exclusão. Como ainda restam valores altos, análises de tempo devem usar a mediana ao invés da média.

Implementação

Célula D4

```
df.loc[df["minutes"] == 0, "minutes"] = np.nan
df.loc[df["minutes"] == 2147483647, "minutes"] = np.nan
```

Validação após o tratamento

1.095 valores ausentes em '*minutes*'. O menor tempo passou a ser 1 minuto e maior tempo 1.051.200 minutos. A média caiu de 9.398 para 128 minutos, enquanto a mediana se manteve em 40.

```
# D4 trocar tempos impossíveis por vazio (NaN)
df.loc[df["minutes"] == 0, "minutes"] = np.nan
df.loc[df["minutes"] == 2147483647, "minutes"] = np.nan
print("Tempos agora vazios:", df["minutes"].isna().sum())
print("Menor tempo:", df["minutes"].min())
print("Maior tempo:", df["minutes"].max())
print("Média:", round(df["minutes"].mean(), 2), "| Mediana:", df["minutes"].median())
```

```
Tempos agora vazios: 1095
Menor tempo: 1.0
Maior tempo: 1051200.0
Média: 128.25 | Mediana: 40.0
```

5. Decisão e diagnóstico

D5 • relacionado a Q14

Problema e abrangência

Indicador de calorias em nutrition, com valor máximo de 434.360 kcal contra mediana de 313 kcal.

Tratamento e justificativa

Decisão de manter os valores sem alteração. As calorias dependem do rendimento da receita, então não há um limite claro que separe erro de valor legítimo. Seguindo o critério de que valor extremo, por si só, não justifica exclusão, os dados foram mantidos, e análises nutricionais devem considerar a mediana.

Implementação

Não se aplica (decisão de manter).

Validação após o tratamento

Os valores de calorias permanecem iguais aos observados no diagnóstico (Q14).

6. Decisão e diagnóstico

D6 • relacionado a Q4 e Q5

Problema e abrangência

'submitted' armazenado como texto, e tags, steps, ingredients e nutrition armazenados como texto que representa lista. Afeta todos os registros dessas 5 colunas.

Tratamento e justificativa

Conversão de '*submitted'* para o tipo data e das outras quatro colunas para listas reais. Além disso, '*nutrition'* foi separada em 7 colunas numéricas. Sem essa conversão não é possível fazer análises por período, contar tags e ingredientes nem calcular indicadores nutricionais. A conversão não altera nenhum valor, apenas o formato.

Implementação

Célula D6

Validação após o tratamento

'submitted' passou a ser do tipo '*datetime64'*, *'tags'* passou a ser do tipo '*list'*, e as 7 novas colunas nutricionais aparecem com valores numéricos correspondentes às primeiras receitas da base.

```
# D6 converter tipos e formatos
df["submitted"] = pd.to_datetime(df["submitted"])

for coluna in ["tags", "steps", "ingredients", "nutrition"]:
    df[coluna] = df[coluna].apply(ast.literal_eval)

colunas_nutri = ["calories", "total_fat_pdv", "sugar_pdv", "sodium_pdv", "protein_pdv", "saturated_fat_pdv", "carbohydrates_pdv"]
df[colunas_nutri] = pd.DataFrame(df["nutrition"].tolist(), index=df.index)

print("Tipo de submitted:", df["submitted"].dtype)
print("Tipo de tags:", type(df["tags"].iloc[0]))
display(df[colunas_nutri].head())
```

```
Tipo de submitted: datetime64[ns]
Tipo de tags: <class 'list'>
```

	calories	total_fat_pdv	sugar_pdv	sodium_pdv	protein_pdv	saturated_fat_pdv	carbohydrates_pdv
0	51.5	0.0	13.0	0.0	2.0	0.0	4.0
1	173.4	18.0	0.0	17.0	22.0	35.0	1.0
2	269.8	22.0	32.0	48.0	39.0	27.0	5.0
3	368.1	17.0	10.0	2.0	14.0	8.0	20.0
4	352.9	1.0	337.0	23.0	3.0	0.0	28.0

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Remoção de receitas duplicadas por nome e autor	5 registros removidos	Célula D1
D2	Remoção de receita sem nome e de receita sem passos	2 registros removidos	Célula D2
D3	Manutenção das receitas sem descrição	4.979 registros mantidos, sem alteração	Célula D3
D4	Tempos impossíveis substituídos por ausente. Demais tempos longos mantidos	1.095 valores em minutes	Célula D4
D5	Manutenção das calorias extremas	Nenhum registro alterado	Diagnóstico Q14
D6	Conversão de submitted para data, das listas para formato de lista e separação de nutrition em 7 colunas	5 colunas convertidas e 7 colunas criadas	Célula D6

RA1 / 05

Conjunto de dados resultante

Identifique a saída do RA1 e demonstre sua consistência para uso nas próximas etapas.

Arquivo ou conjunto final: *'recipes_ra1.parquet'* gerado pela célula 22 do notebook na pasta data/, em formato Apache Parquet, com 231.630 linhas × 19 colunas. O arquivo não é versionado porque é gerado novamente a cada execução. Escolhemos o Parquet porque ele preserva os tipos e porque é compatível com o Spark.

Unidade de observação final: uma linha representa uma receita única publicada no Food.com entre 06/08/1999 e 04/12/2018, identificada pelo id e sem repetição do par nome + autor.

Dicionário atualizado: Dicionário Final da seção 7. Parte do dicionário inicial da seção 3 com a inclusão das 7 colunas nutricionais criadas no D6 e os novos tipos das colunas convertidas.

Comparação antes e depois

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	231.637	231.630	7 removidos, 5 duplicados por nome + autor, 1 receita sem nome e 1 receita sem passos
Atributos	12	19	7 colunas criadas a partir da coluna *'nutrition'*, nenhuma removida e mantemos a 'nutrition' para rastreabilidade.
Duplicatas nome + autor.	5	0	Remoção mantendo o primeiro registro.
Receitas sem nome ou sem passos	2	0	Removidos.
'minutes' com valores impossíveis ou zerados.	1.095	0	Substituidos por ausentes. Tempos muito longos foram mantidos.
Ausentes em 'minutes'	0	1.095	Consequência direta do D4
Ausente em 'description'	4.979	4.979	Mantidos por serem opcionais
Colunas com tipo inadequado	5	0	Conversão para data e lista.

Exemplo de medida de qualidade: número de registros duplicados conforme a chave definida. Se usar percentuais, indique o denominador.

Verificações finais

- **Tipos:** *'submitted'* está como *'datetime64',* as 7 colunas nutricionais como *'float64'* e *'id', 'contributor_id', 'n_ingredients' e 'n_steps'* como inteiro. *'minutes'* ficou como float para poder ser nulo.

- **Domínios:** nenhuma receita tem minutos, número de ingredientes e passos zerados, não tem valor negativo em nenhuma coluna e as datas vão de 06/08/1999 a 04/12/2018.
- **Ausências:** só aparecem na coluna de minutos e descrição, o que ja era esperado.
- **Duplicidades:** nenhuma
- **Integridade:** as colunas '*n_steps' e 'n_ingredients'* batem com os valores das colunas '*steps'* e *'ingredients'*, respectivamente, que agora são listas.

Limitações e pendências

- **Tempos longos mantidos:** a coluna de minutos ainda tem números muito altos, até porque existem receitas que podem levar dias, como marinadas e fermentações. Quando precisar fazer uma análise de tempo o ideal seria usar a mediana.
- **Receitas sem tempo de preparo:** as 1095 receitas que não tem a coluna minutes preenchida ficam de fora das análises de tempo.
- **Calorias extremas mantidas:** Como as receitas não são necessariamente para uma porção, não podemos limitar.
- **Unidades nutricionais diferentes:** a coluna calorias tem um valor absoluto, as outras estão em % do valor diário. Por serem medidas diferentes não podem ser somadas nem comparadas.
- **Culinária e restrições alimentares:** *cuisine_primary* e *dietary_tags* ainda não existem como colunas e continuam dentro de *tags*. A extração e a regra de culinária principal ficam para o RA2.

LIMITE DESTA ENTREGA
Agregações analíticas, indicadores, visualizações e conclusões pertencem aos próximos RAs. Aqui, demonstre a qualidade e a consistência dos dados preparados.

RA1 / 06

Organização e reprodutibilidade

Explique como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão: https://github.com/giovanisims/Dishly-Data

Ambiente: Python 3.13.16 no Google Colab • pandas 2.2.3, numpy 2.1.3, pyarrow 23.0.1, kagglehub 1.0.2 • dependências em requirements.txt

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	RAW_recipes.csv, baixado pelo notebook com o kagglehub a partir do dataset público shuyangli94/food-com-recipes-and-user-interactions do Kaggle. Não fica no repositório.
Código de ingestão e preparação	notebooks/RA1_Ingestion_Quality.ipynb
Dados preparados	data/recipes_ra1.parquet, gerado pela célula 22. Não fica no repositório.
Documentação e dependências	README • este documento • requirements.txt

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	Abrir notebooks/RA1_Ingestion_Quality.ipynb no Google Colab (Arquivo → Abrir notebook → GitHub → colar a URL do repositório). Fora do Colab, criar um ambiente virtual (venv), instalar as dependências com pip install -r requirements.txt.	A célula de versões mostra Python, pandas, numpy, pyarrow e kagglehub.
2	Executar a célula 2. Ela baixa a base do Kaggle sem download manual, conta ou chave de acesso.	"Dados carregados com sucesso!" e 231.637 linhas × 12 colunas, conferidas pelo assert.
3	Executar as demais células na ordem (Ambiente de execução → Executar tudo).	Todas as células rodam sem erro.
4	Conferir a saída data/recipes_ra1.parquet no painel de arquivos do Colab.	231.630 linhas × 19 colunas, conferidas pelo assert, e verificações finais com 0 duplicatas, 0 valores negativos e 0 divergências de integridade.

Verificação da reprodução

21/10/2026, Sarah, Google Colab, Python 3.13.16, pandas 2.2.3, execução completa a partir do repositório. A base final ficou com 231.630 linhas × 19 colunas. As verificações finais não encontraram duplicatas, valores zerados ou negativos, nem divergências de integridade. As únicas ausências são as esperadas.

Quando houver restrições de acesso aos dados, explique como um avaliador autorizado poderá reproduzir a execução. Documente configurações necessárias sem expor credenciais.

RA1 / 07

Referências e anexos

Reúna as fontes utilizadas e os materiais complementares que ajudam a verificar a entrega.

Referências

Inclua fontes de dados, documentação técnica e materiais efetivamente utilizados. Adote o padrão solicitado na disciplina; mantenha a identificação e os links consistentes.

APACHE SOFTWARE FOUNDATION. **Apache Arrow**: PyArrow. Versão 23.0.1. Disponível em: https://arrow.apache.org/docs/python/. Acesso em: 21 out. 2026.

KAGGLE. **kagglehub**. Versão 1.0.2. Disponível em: https://github.com/Kaggle/kagglehub. Acesso em: 21 out. 2026.

LI, Shuyang. **Food.com Recipes and Interactions.** Kaggle, 2019. Conjunto de dados. Disponível em: https://www.kaggle.com/datasets/shuyangli94/food-com-recipes-and-user-interactions. Acesso em: 21 out. 2026.

MAJUMDER, Bodhisattwa Prasad; LI, Shuyang; NI, Jianmo; MCAULEY, Julian. Generating personalized recipes from historical user preferences. *In*: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING AND INTERNATIONAL JOINT CONFERENCE ON NATURAL LANGUAGE PROCESSING, 2019, Hong Kong. **Proceedings** [...]. Hong Kong: Association for Computational Linguistics, 2019. p. 5976–5982. DOI: 10.18653/v1/D19-1613. Disponível em: https://aclanthology.org/D19-1613/. Acesso em: 21 out. 2026.

PANDAS DEVELOPMENT TEAM. **pandas**: Python data analysis library. Versão 2.2.3. Disponível em: https://pandas.pydata.org/docs/. Acesso em: 21 out. 2026.

Anexos opcionais

Identificação	Conteúdo	Localização
Dicionário Final	Dicionário atualizado da base final (19 atributos)	Logo abaixo

Dicionário Final

Atributo	Significado	Tipo e formato	Unidade ou domínio
name	Nome da receita	object (string)	Texto livre
id	Identificador único da receita na plataforma	int64	Inteiro positivo
minutes	Tempo total estimado de preparo	float64	Minutos, de 1 a 1.051.200; 1.095 ausentes

contributor_id	Identificador único do usuário autor	int64	Inteiro positivo
submitted	Data de publicação da receita	datetime64	Datas entre 1999 e 2018
tags	Palavras-chave da receita	list	Lista de strings, pelo menos 1 tag.
nutrition	Vetor com 7 indicadores nutricionais	list	[calories, total_fat_pdv, sugar_pdv, sodium_pdv, protein_pdv, saturated_fat_pdv, carbohydrates_pdv]
n_steps	Quantidade de passos de preparo	int64	Contagem inteira >= 1
steps	Modo de preparo, passo a passo.	list	Lista de strings, tamanho igual a n_steps
description	Texto introdutório do autor	object (string)	Texto livre, opcional; 4.979 ausentes
ingredients	Ingredientes utilizados na receita	list	Lista de strings
n_ingredients	Quantidade de ingredientes da receita	int64	Contagem inteira >= 1 e igual ao tamanho de ingredients
calories	Calorias por porção	float64	Nova, extraída de nutrition; extremos mantidos (D5)
total_fat_pdv	Gordura total por porção	float64	Nova, extraída de nutrition (D6)
sugar_pdv	Açúcar por porção	float64	Nova, extraída de nutrition (D6)
sodium_pdv	Sódio por porção	float64	Nova, extraída de nutrition (D6)
protein_pdv	Proteína por porção	float64	Nova, extraída de nutrition (D6)
saturated_fat_pdv	Gordura saturada por porção	float64	Nova, extraída de nutrition (D6)
carbohydrates_pdv	Carboidratos por porção	float64	Nova, extraída de nutrition (D6)

Remova a seção de anexos se não houver materiais complementares. Prefira referenciar os arquivos do repositório a repetir grandes blocos de código no documento.

Conferência da entrega

x Problema, recorte e perguntas analíticas estão definidos.

x Fontes e procedimentos de ingestão estão documentados.

x A qualidade foi avaliada com evidências verificáveis.

x As decisões de limpeza estão justificadas e validadas.

x O conjunto de dados preparado está identificado.

x O repositório contém instruções suficientes para reprodução.

x Os campos-modelo foram preenchidos e os exemplos revisados.